Влияние качества Semantic ID на финальные метрики

Константин Рядинский • Лев Клюев • Ростислав Головков • Глеб Шевченко • Ментор: Александр Новак

Введение

Semantic IDs (SIDs) используются для дискретного представления объектов в генеративных рекомендательных системах. В нашей работе SID строятся на основе **контентной информации** об объектах. При этом качество SID часто оценивается через **свойства самого представления**, которые не обязательно коррелируют с качеством итоговых рекомендаций.

Цель нашей работы: исследовать эту связь, сравнить различные методы построения Semantic IDs и определить, какие свойства SID действительно отражаются на финальных метриках рекомендательной системы.

Сравниваемые модели

Генерация без Semantic IDs

SASRec: Transformer-бейзлайн, который кодирует историю взаимодействий и предсказывает следующий объект по его item ID.

Генерация с Semantic IDs

TIGER-like авторегрессионно генерирует последовательность токенов SID целевого объекта.

Ранжирование без Semantic IDs

Базовые ранжирующие модели используют обычные **item ID**:

DCNv2 объединяет счётчики и категориальные признаки в cross- и deep-блоках.

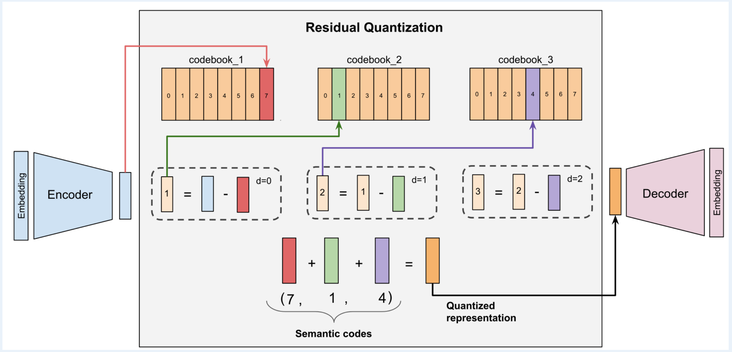
TransAct-like использует те же признаки и дополнительно принимает историю взаимодействий пользователя.

Ранжирование с Semantic IDs

Обе модели дополнительно получают **SID целевого объекта**. В **TransAct-like** item ID в истории также заменяются соответствующими SID.

Так мы измеряем эффект одного и того же SID в двух сценариях: **ранжировании** и **генерации**.

Balanced RQ-KMeans / RQ-VAE



Источник: Mike X Cohen (2026), схема Sumit

PLUM-like

Число кодов уменьшается вдвое с каждым уровнем:

$$C_i = \frac{C_0}{2^i}.$$

При обучении случайно выбирается длина **активного префикса**: обновляются только первые уровни SID.

Полная глубина выбирается с вероятностью **0.25**; остальные длины делят оставшуюся вероятность.

Поэтому ранние токены обучаются чаще, а каждый короткий префикс остаётся информативным.

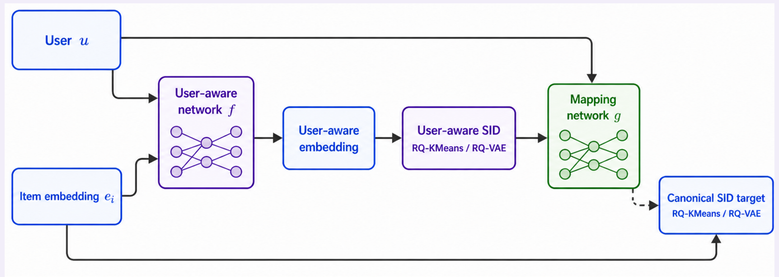
R3-VAE

Обучаемый **опорный вектор** задаёт семантический якорь для начального остатка.

Оценка скалярным произведением сохраняет градиент и снижает риск вырождения кодбука.

Регуляризация **SC/PD** сближает объекты внутри кластера и разделяет разные паттерны предпочтений.

User-aware



PSI

Первые токены передают **основную информацию**, а последующие добавляют детали. Случайное маскирование хвоста делает полезным каждый **префикс SID**.

Spectral embeddings

Эксперименты и графики

Главный результат