Влияние качества Semantic ID на финальные метрики

Константин Рядинский • Лев Клюев • Ростислав Головков • Глеб Шевченко • Ментор: Александр Новак

Введение

Semantic IDs (SIDs) используются для дискретного представления объектов в генеративных рекомендательных системах. При этом качество SID часто оценивается через свойства самого представления, которые не обязательно коррелируют с качеством итоговых рекомендаций.

Цель нашей работы - исследовать эту связь: сравнить различные методы построения Semantic IDs и определить, какие свойства SID действительно отражаются на финальных метриках рекомендательной системы.

Постановка эксперимента

Что хотим выяснить

Хотим изучить зависимость между **метриками Semantic ID** и **downstream-метриками** рекомендательных моделей.
Рассматриваем: **генерацию** следующих объектов и **ранжирование** кандидатов.

Генерация

TIGER авторегрессионно предсказывает SID следующего объекта.
В качестве baseline используем **SASRec**, который предсказывает следующий объект напрямую по item ID.

Ранжирование

DCNv2 ранжирует объект по счётчикам и признакам. SID целевого объекта подаётся в модель как дополнительный признак.
TransAct-like расширяет DCNv2 пользовательской историей: помимо тех же признаков модель получает историю взаимодействий пользователя, в которой item ID заменены на SID соответствующих объектов.

Датасет и разбиение

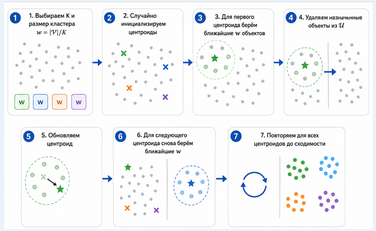
Все эксперименты ставим на датасете **Yambda-50M** с **time split**.

Downstream-метрики

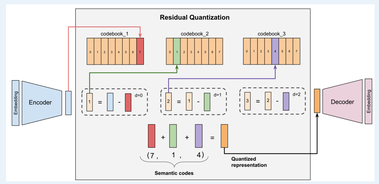
Для генерации: Recall@100.
Для ранжирования: ROC-AUC и pairwise accuracy.

Balanced RQ-KMeans / RQ-VAE

Balanced RQ-KMeans



RQ-VAE



Источник: Mike X Cohen (2026), схема Sumit

PLUM-like

Число кодов уменьшается вдвое с каждым уровнем:

$$C_i = \frac{C_0}{2^i}.$$

При обучении случайно выбирается длина **активного префикса**: обновляются только первые уровни SID.

Полная глубина выбирается с вероятностью **0.25**; остальные длины делят оставшуюся вероятность.

Поэтому ранние токены обучаются чаще, а каждый короткий префикс остаётся информативным.

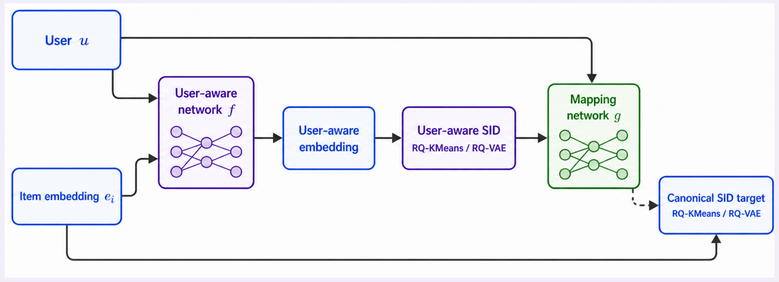
R3-VAE

Обучаемый **опорный вектор** задаёт семантический якорь для начального остатка.

Оценка скалярным произведением сохраняет градиент и снижает риск вырождения кодбука.

Регуляризация **SC/PD** сближает объекты внутри кластера и разделяет разные паттерны предпочтений.

User-aware



PSI

PSI устраняет **коллизии без дополнительного токена**: если ближайший SID уже занят, объект получает следующую близкую свободную комбинацию кодов.

LogQ

SID LogQ: корректируем логиты токенов по частоте SID-префиксов.

Item ID + SID: добавляем item-level loss с LogQ по частоте объектов.

Эксперименты и графики

Главный результат