Влияние качества Semantic ID на финальные метрики

Константин Рядинский • Лев Клюев • Ростислав Головков • Глеб Шевченко

Ментор: Александр Новак

Введение

Semantic ID (SID) кодирует объект короткой последовательностью дискретных токенов и позволяет модели работать с семантикой вместо произвольных item ID.

Но хорошие **свойства самого представления** --- баланс кодбука, низкая доля коллизий, точная реконструкция --- не гарантируют роста итоговых метрик.

Цель работы --- сравнить методы построения SID и выяснить, какие характеристики представления действительно предсказывают качество **ранжирования** и **генерации**.

Сравниваемые модели

Генерация без Semantic IDs

SASRec --- Transformer-бейзлайн: кодирует историю взаимодействий и предсказывает следующий объект по его item ID.

Генерация с Semantic IDs

TIGER-like авторегрессионно генерирует последовательность токенов SID целевого объекта.

Ранжирование без Semantic IDs

Базовые ранжирующие модели используют обычные **item ID**:

DCNv2 объединяет счётчики и категориальные признаки в cross- и deep-блоках.

TransAct-like использует те же признаки и дополнительно принимает историю взаимодействий пользователя.

Ранжирование с Semantic IDs

Обе модели дополнительно получают **SID целевого объекта**. В **TransAct-like** item ID в истории также заменяются соответствующими SID.

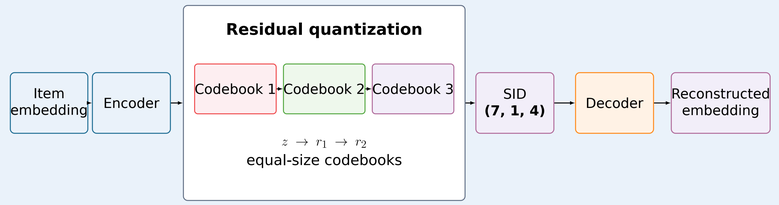
Так мы измеряем эффект одного и того же SID в двух сценариях: **ранжировании** и **генерации**.

Дополнительные методы

Эксперименты и графики

Главный результат

Balanced RQ-KMeans / RQ-VAE



Адаптировано по схеме residual quantization

PLUM-like

Число кодов уменьшается вдвое с каждым уровнем:

$$C_i = \frac{C_0}{2^i}.$$

При обучении случайно выбирается длина **активного префикса**: обновляются только первые уровни SID.

Полная глубина выбирается с вероятностью **0.25**; остальные длины делят оставшуюся вероятность.

Поэтому ранние токены обучаются чаще, а каждый короткий префикс остаётся информативным.

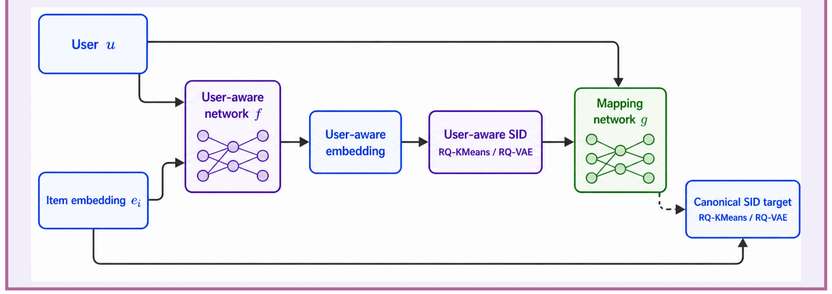
R3-VAE

Обучаемый **опорный вектор** задаёт семантический якорь для начального остатка.

Оценка скалярным произведением сохраняет градиент и снижает риск вырождения кодбука.

Регуляризация **SC/PD** сближает объекты внутри кластера и разделяет разные паттерны предпочтений.

User-aware



PSI

Первые токены SID содержат **основную информацию** об объекте, а последующие уточняют представление.

При обучении последние токены случайно скрываются. Поэтому модель учится строить полезное представление даже по **короткому префиксу** SID.

Spectral embeddings