Влияние качества Semantic ID на финальные метрики

Константин Рядинский • Лев Клюев • Ростислав Головков • Глеб Шевченко

Ментор: Александр Новак

Введение

Semantic IDs (SIDs) используются для дискретного представления объектов в генеративных рекомендательных системах.

При этом качество SID часто оценивается через **свойства самого представления**, которые не обязательно коррелируют с качеством итоговых рекомендаций.

Цель нашей работы --- исследовать эту связь: сравнить различные методы построения Semantic IDs и определить, какие свойства SID действительно отражаются на финальных метриках рекомендательной системы.

Бэйзлайны

Генерация без Semantic IDs

SASRec --- одна из первых моделей трансформеров, использующая историю взаимодействий пользователя с айтемами.

Генерация с Semantic IDs

TIGER-like --- генеративная рекомендательная модель, которая авторегрессионно предсказывает последовательность токенов Semantic ID целевого объекта.

Ранжирование без Semantic IDs

В качестве базовых моделей используем стандартные ранжирующие модели, работающие с обычными **item ID**:

DCNv2 --- надо написать, в чём прикол именно этой модели.

TransAct-like --- надо написать, в чём прикол именно этой модели.

Ранжирование с Semantic IDs

Для тех же ранжирующих моделей мы добавляем к обычному индексу объекта его **Semantic ID**. Это позволяет напрямую оценить, как способ построения SID влияет на качество ранжирования.

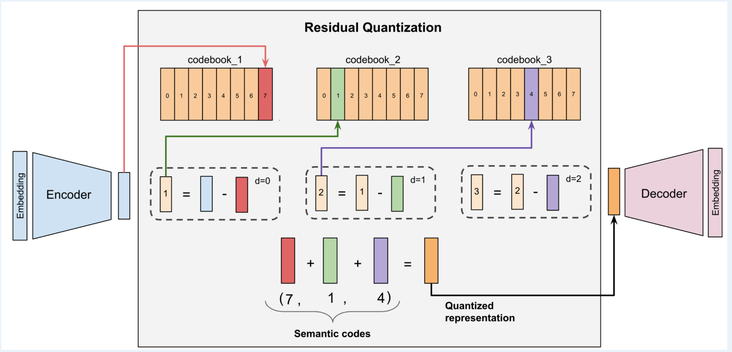
Таким образом, влияние SID оцениваются как в **ранжировании**, так и в **генерации**.

Гибкая зона: 1--2 метода после примерки текста (объясните, что это))

Эксперименты и графики

Главный результат

Balanced RQ-KMeans / RQ-VAE



Источник: Mike X Cohen (2026), схема Sumit

PLUM-like

Размер кодбука уменьшается вдвое с каждым уровнем:

$$C_i = \frac{C_0}{2^i}.$$

Случайная **prefix-маска** выбирает глубину SID: обновляются только уровни активного префикса.

Последний кодбук используется с вероятностью **0.25**; остальные глубины делят оставшуюся вероятность.

Ранние уровни обучаются чаще и формируют информативные короткие префиксы SID.

R3-VAE

Обучаемый **reference-вектор** задаёт семантический якорь для начального residual.

Dot-product rating сохраняет поток градиента и предотвращает collapse кодбука.

Регуляризация **SC**/**PD** усиливает сходство внутри SID и различия между кластерами.

User-aware

BPE

PSI

Multi-resolution кодбуки уменьшаются на глубоких уровнях и компактно кодируют residual.

Progressive masking обучает случайные SID-префиксы, усиливая семантическую иерархию.

Spectral embeddings