Влияние качества Semantic ID на финальные метрики

Константин Рядинский • Лев Клюев • Ростислав Головков • Глеб Шевченко • Ментор: Александр Новак

Введение

Semantic IDs (SIDs) используются для дискретного представления объектов в генеративных рекомендательных системах. При этом качество SID часто оценивается через свойства самого представления, которые не обязательно коррелируют с качеством итоговых рекомендаций.

Цель нашей работы - исследовать эту связь: сравнить различные методы построения Semantic IDs и определить, какие свойства SID действительно отражаются на финальных метриках рекомендательной системы.

Постановка эксперимента

Что хотим выяснить

Связаны ли метрики качества Semantic ID с качеством рекомендаций? И сохраняется ли эта связь при переходе от одной задачи и модели к другой?

метрики SID $\longrightarrow$ **downstream-метрики**

Единый протокол сравнения

Все варианты SID проверяем на датасете **Yambda-50M** и с единым временным разбиением. Для downstream-моделей используем одинаковые настройки обучения.

Генерация

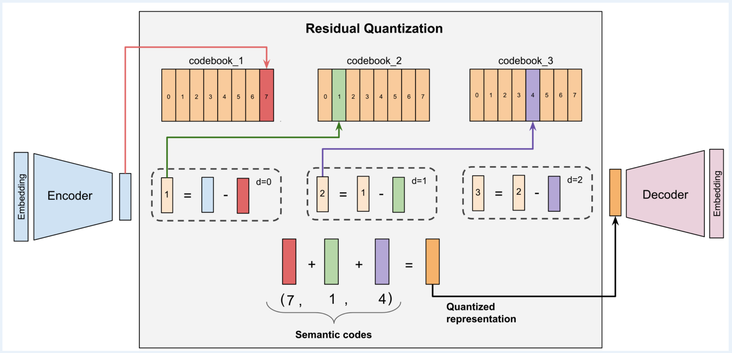
TIGER-like авторегрессионно предсказывает SID следующего объекта.
Качество измеряем по **Recall@100**.
В качестве ориентира используем **SASRec**, который предсказывает следующий объект напрямую по item ID.

Ранжирование

Проверяем два сценария: **DCNv2** без истории и **TransAct-like** с последовательностью взаимодействий пользователя.
SID целевого объекта используется в обеих моделях, а в TransAct-like дополнительно кодирует объекты из истории.
Качество измеряем по **ROC-AUC** и **pairwise accuracy**.

Для каждого варианта SID получаем результаты во всех трёх моделях и сравниваем, какие метрики SID действительно согласуются с ростом итогового качества.

Balanced RQ-KMeans / RQ-VAE



Источник: Mike X Cohen (2026), схема Sumit

PLUM-like

Число кодов уменьшается вдвое с каждым уровнем:

$$C_i = \frac{C_0}{2^i}.$$

При обучении случайно выбирается длина **активного префикса**: обновляются только первые уровни SID.

Полная глубина выбирается с вероятностью **0.25**; остальные длины делят оставшуюся вероятность.

Поэтому ранние токены обучаются чаще, а каждый короткий префикс остаётся информативным.

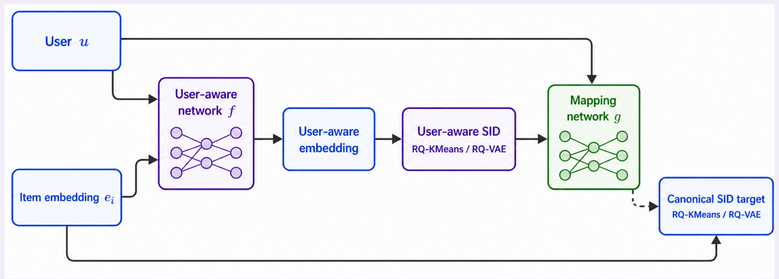
R3-VAE

Обучаемый **опорный вектор** задаёт семантический якорь для начального остатка.

Оценка скалярным произведением сохраняет градиент и снижает риск вырождения кодбука.

Регуляризация **SC/PD** сближает объекты внутри кластера и разделяет разные паттерны предпочтений.

User-aware



PSI

Первые токены передают **основную информацию**, а последующие добавляют детали. Случайное маскирование хвоста делает полезным каждый **префикс SID**.

Spectral embeddings

Эксперименты и графики

Главный результат