Влияние качества Semantic ID на финальные метрики

Константин Рядинский • Лев Клюев • Ростислав Головков • Глеб Шевченко • Ментор: Александр Новак

Введение

Semantic IDs (SIDs) используются для дискретного представления объектов в генеративных рекомендательных системах.

При этом качество SID часто оценивается через свойства самого представления, которые не обязательно коррелируют с качеством итоговых рекомендаций.

Цель нашей работы — исследовать эту связь: сравнить различные методы построения Semantic IDs и определить, какие свойства SID действительно отражаются на финальных метриках рекомендательной системы.

Внутреннее качество дискретного представления само по себе не гарантирует улучшение downstream-модели, поэтому связь между SID и итоговыми метриками нужно проверять отдельно.

Постановка эксперимента

Что хотим выяснить

Хотим изучить зависимость между метриками Semantic ID и downstream-метриками рекомендательных моделей. Рассматриваем: генерацию следующих объектов и ранжирование кандидатов.

Генерация

TIGER авторегрессионно предсказывает SID следующего объекта. В качестве baseline используем SASRec, который предсказывает следующий объект напрямую по item ID.

Ранжирование

DCNv2 ранжирует объект по счётчикам и признакам. SID целевого объекта подаётся в модель как дополнительный признак. TransAct-like расширяет DCNv2 пользовательской историей: модель получает историю взаимодействий, в которой item ID заменены на SID соответствующих объектов.

Датасет и разбиение

Все эксперименты ставим на датасете Yambda-50M с time split.

Downstream-метрики

Для генерации: Recall@100.
Для ранжирования: ROC-AUC и Pairwise Accuracy.

Ключевые метрики SID

Independent Code Rate (ICR).
Доля уникальных использованных SID-кодов относительно числа объектов:

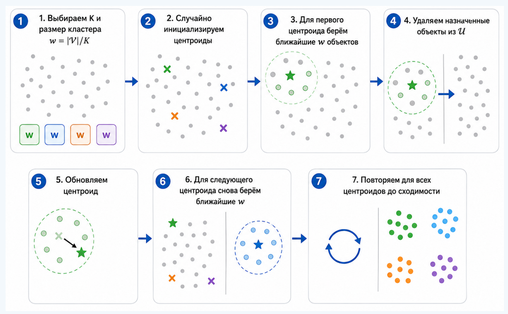
$$\mathrm{ICR} = \frac{\mathrm{nunique\ \ used\ \ codes}}{\mathrm{nitems}}$$

Чем ближе ICR к 1, тем меньше объектов разделяют один и тот же SID.

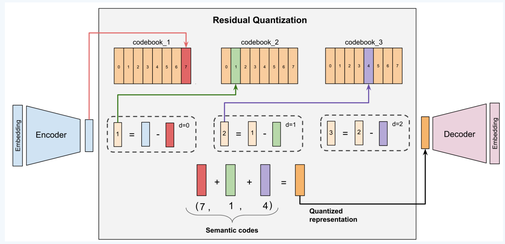
Intra-code Similarity.
Средняя семантическая близость объектов, получивших одинаковый код.
Чем выше значение, тем семантически однороднее группы объектов.

Balanced RQ-KMeans / RQ-VAE

Balanced RQ-KMeans



RQ-VAE



Источник: Mike X Cohen (2026), схема Sumit

PLUM-like

Число кодов уменьшается вдвое с каждым уровнем:

$$C_i = \frac{C_0}{2^i}$$

При обучении случайно выбирается длина активного префикса: обновляются только первые уровни SID.

Полная глубина выбирается с вероятностью 0.25; остальные длины делят оставшуюся вероятность.

Поэтому ранние токены обучаются чаще, а каждый короткий префикс остаётся информативным.

R3-VAE

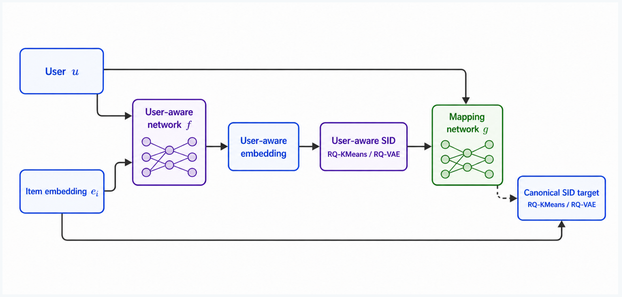
Обучаемый опорный вектор задаёт семантический якорь для начального остатка.

$$s(r_0, \mathbf{a}) = \langle r_0, \mathbf{a} \rangle$$

Оценка скалярным произведением сохраняет градиент и снижает риск вырождения кодбука.

Регуляризация SC/PD сближает объекты внутри кластера и разделяет разные паттерны предпочтений.

User-aware



PSI

PSI устраняет коллизии без дополнительного токена: если ближайший SID уже занят, объект получает следующую близкую свободную комбинацию кодов.

Отдельно сравниваются два метода: RRS и ECM.

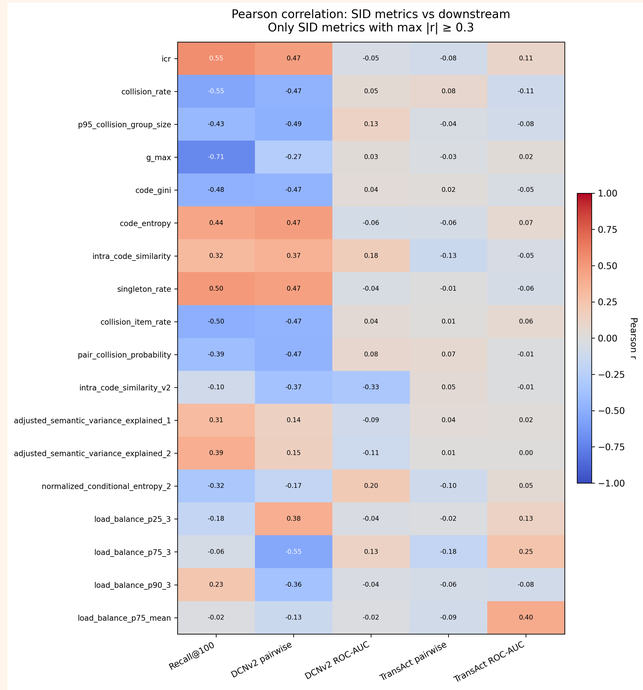
LogQ

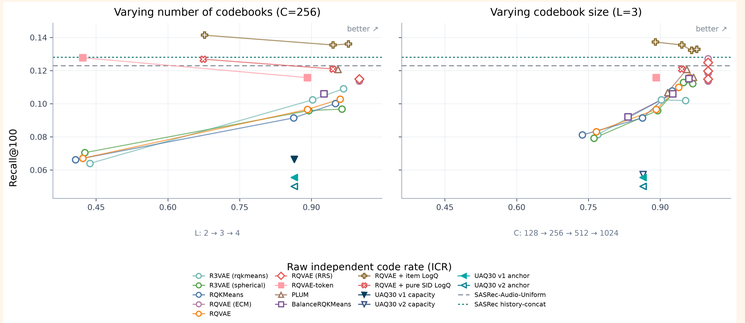
SID LogQ: корректируем логиты токенов по частоте SID-префиксов.

Item ID + SID: добавляем item-level loss с LogQ по частоте объектов.

$$L_{\mathrm{total}} = L_{\mathrm{SID}} + 0.1\, L_{\mathrm{item}}$$

Эксперименты и графики





Задача	Baseline	Лучший SID	Δ, %
Ранжирование TransAct · Pairwise Accuracy	TransAct item-only **0.76164**	RQVAE (L=3, C=1024) **0.63811**	-16.2%
Ранжирование DCNv2 · Pairwise Accuracy	DCNv2 (item-only) **0.54914**	RQVAE (ECM), L=3, C=256 **0.53600**	-2.4%
Генерация Recall@100	SASRec-Audio-Uniform **0.12303**	RQVAE + item LogQ (L=2, C=256) **0.14138**	+14.9%

